Aplicación de la metodología TDSP a la investigación

Introducción

La metodología Team Data Science Process (TDSP) es un proceso de trabajo para desarrollar proyectos de ciencia de datos de forma ordenada, desde la definición del problema hasta la evaluación de los resultados. En esta investigación se utilizará para estructurar el análisis de la relación entre la práctica de natación o actividades acuáticas y el bienestar mental de estudiantes universitarios. Su aplicación permitirá seleccionar las variables más útiles de la base de datos, preparar la información, establecer un modelo estadístico y presentar resultados que respondan a la pregunta de investigación. En esta tarea se describen las cinco etapas de TDSP adaptadas al proyecto: comprensión del problema, adquisición y comprensión de los datos, modelado, implementación y evaluación de los resultados.

Roles organizacionales

Líder de equipo/Científico de datos: María Sayuri Baltazar Pedraza

Líder de proyecto/Arquitecto de datos: Javier Zair Galan Trujillo

Estadístico/Experto en la materia: Jorge Luis Ortiz libreros

Gestor del proceso/Analista de datos: Oscar Alberto Domínguez Ortega

1. Comprensión del problema

En esta etapa se define con claridad qué se desea estudiar y cuál será el propósito del análisis. La investigación busca analizar si la práctica de natación o de actividades acuáticas se encuentra asociada con mejores indicadores de salud mental y bienestar en estudiantes universitarios.

La pregunta que orienta el análisis es: ¿los estudiantes universitarios que practican natación o actividades acuáticas presentan mejores niveles de bienestar mental que aquellos que no las practican?

A partir de esta pregunta, el objetivo del análisis será identificar si existe una relación entre la práctica de actividades acuáticas y el bienestar mental, considerando además otras características de los estudiantes que podrían influir en dicha relación.

Las variables principales que se considerarán son:

- Actividad acuática: variables relacionadas con watersport y el tiempo destinado a estas actividades.
- Bienestar mental: reactivos wemwbs1 a wemwbs7.
- Características personales: edad y género.
- Actividad física general: cantidad de deporte realizado y participación en clubes deportivos.

- Sueño: horas de sueño.
- Variables complementarias: rendimiento académico u otras características disponibles que puedan ayudar a interpretar los resultados.

Antes de utilizar watersport como equivalente directo de natación, será necesario verificar en la documentación o diccionario de la base si esta variable incluye específicamente natación o si agrupa diferentes deportes acuáticos. Esta revisión evitará atribuir a la natación un resultado que corresponda a un grupo más amplio de actividades.

2. Adquisición y comprensión de los datos

Para realizar el análisis se utilizará la base de datos ALL_aun_pacs210914.csv. Esta base contiene información de estudiantes universitarios relacionada con actividad física, estilos de vida, bienestar y características sociodemográficas.

En esta etapa se realizará una exploración inicial de los datos con el objetivo de conocer su estructura, identificar las variables necesarias y comprobar que la información pueda utilizarse para responder la pregunta de investigación.

Entre las variables de interés se encuentran:

- watersport: participación en actividades o deportes acuáticos.
- watersport_wkdy y watersport_wkend: práctica de actividades acuáticas entre semana y durante el fin de semana.
- watersport_wkdy_t y watersport_wkend_t: tiempo destinado a actividades acuáticas.
- wemwbs1 a wemwbs7: reactivos relacionados con bienestar mental.
- age: edad.
- gender: género.
- hrs_slept: horas de sueño.
- sport_total: actividad deportiva total.
- sport_club: participación en un club deportivo.
- gpa_st: información relacionada con el desempeño académico.

La preparación de los datos incluirá la revisión de:

- Valores faltantes.
- Valores atípicos o inconsistentes.
- Posibles registros duplicados.

- Codificación de las variables categóricas.
- Distribución de las variables principales.
- Cantidad de estudiantes que realizan actividades acuáticas y cantidad de estudiantes que no las realizan.

Posteriormente, y siempre respetando la forma de puntuación establecida para el instrumento original, se podrá construir una puntuación global de bienestar mental a partir de los siete reactivos wemwbs1 a wemwbs7. Esto permitirá contar con una sola medida cuantitativa para comparar a los estudiantes y utilizarla como variable de respuesta en el modelo.

También se obtendrán estadísticas descriptivas, como medias, desviaciones estándar, frecuencias y porcentajes, para conocer las características principales de la muestra y describir el comportamiento de las variables antes de realizar el modelado.

3. Modelado

Una vez preparada la base de datos se realizará el análisis estadístico para estudiar la posible relación entre la actividad acuática y el bienestar mental.

Como primer análisis, los estudiantes podrán clasificarse en dos grupos de acuerdo con la codificación disponible: estudiantes que practican actividades acuáticas y estudiantes que no las practican. Posteriormente se comparará el nivel promedio de bienestar mental entre ambos grupos.

Como modelo principal se propone utilizar una regresión lineal múltiple. La puntuación de bienestar mental funcionará como variable dependiente y la práctica de actividades acuáticas será la principal variable explicativa. Además, se incluirán otras características que podrían influir en el bienestar.

$$\textbf{Bienestar mental} = \beta_0 + \beta_1(\textbf{actividad acuática}) + \beta_2(\textbf{edad}) + \beta_3(\textbf{género}) + \beta_4(\textbf{horas de sueño}) + \beta_5(\textbf{actividad física}) + \varepsilon$$

Este modelo permitirá evaluar si la práctica de actividades acuáticas mantiene una asociación con el bienestar mental después de considerar otros factores. Esto es importante porque una diferencia observada entre los grupos podría deberse también a hábitos de sueño, actividad física general, edad u otras características de los participantes.

Para evaluar el modelo se revisarán los coeficientes estimados, su signo y magnitud, los valores p, los intervalos de confianza, el coeficiente de determinación R^2, el R^2 ajustado y el comportamiento de los residuos. También se revisará el cumplimiento de los principales supuestos del modelo.

El objetivo no será únicamente determinar si existe significancia estadística, sino interpretar la dirección y la magnitud de la asociación encontrada entre las actividades acuáticas y el bienestar mental.

4. Implementación de los resultados

En TDSP, la implementación consiste en convertir los resultados del análisis en información que pueda utilizarse. Debido a que este trabajo tiene un propósito académico y de investigación, no será necesario desarrollar una aplicación o sistema informático.

La implementación se realizará mediante la presentación de los principales resultados en tablas, gráficas y explicaciones claras. Se podrán incluir comparaciones del bienestar mental entre estudiantes que practican y no practican actividades acuáticas, así como gráficas que muestren la posible relación entre el tiempo dedicado a estas actividades y el nivel de bienestar.

También se presentarán los resultados del modelo de regresión, destacando el coeficiente correspondiente a la actividad acuática y su interpretación. Esto permitirá traducir los resultados estadísticos en conclusiones relacionadas directamente con la pregunta de investigación.

5. Aceptación y evaluación de los resultados

En la última etapa se verificará si el análisis realizado permite responder adecuadamente al problema planteado al inicio de la investigación.

Se revisará si fue posible identificar correctamente a los estudiantes que realizan actividades acuáticas, construir un indicador adecuado de bienestar mental, comparar los grupos y determinar si la actividad acuática mantiene una asociación con el bienestar después de considerar otras variables.

Si se observa una asociación positiva y estadísticamente significativa, se podrá concluir que, dentro de la muestra analizada, la práctica de actividades acuáticas se relaciona con mayores niveles de bienestar mental. Sin embargo, esta conclusión deberá expresarse como una asociación y no como una relación causal, ya que el análisis de datos observacionales por sí mismo no permite asegurar que la natación sea la causa directa de una mejora en la salud mental.

Lo nuevo que se descubrió para la investigación y para qué sirvió

La aplicación de TDSP permitió identificar con mayor claridad cómo transformar la pregunta general sobre natación y salud mental en un análisis estadístico concreto. Uno de los principales aportes fue reconocer que no basta con comparar el bienestar de quienes practican actividades acuáticas con quienes

no las practican; también es necesario considerar variables como el sueño, la edad, el género y la actividad física general para evitar interpretaciones demasiado simples.

También se identificó que la base contiene variables de actividad acuática y varios reactivos de bienestar mental que pueden utilizarse de manera conjunta. Esto permitió proponer la construcción de una puntuación global de bienestar y establecerla como variable principal del análisis.

Otro aporte importante fue la propuesta de utilizar regresión lineal múltiple. Este modelo servirá para estimar la asociación específica de la actividad acuática con el bienestar mental mientras se mantienen controladas otras características de los estudiantes.

Finalmente, TDSP sirvió para organizar el proyecto como un proceso completo de ciencia de datos: primero se define el problema, después se seleccionan y preparan los datos, se aplica un modelo, se presentan los resultados y al final se verifica si esos resultados responden realmente a la pregunta de investigación. Con ello, la investigación obtiene una estructura más clara, reproducible y enfocada en producir evidencia útil para sus objetivos.