



Universidad Veracruzana



MÉTODOS MULTIVARIADOS

Facultad de Estadística e
Informática, Universidad
Veracruzana

Licenciatura en ingeniería en ciencia
de datos

Docente:
Dra. Julia Aurora Montano Rivas

Trabajo realizado por:
Maria Sayuri Baltazar Pedraza

1 de Diciembre del 2025

ÍNDICE

3

**Análisis de
Componentes
Principales**

6

Análisis Factorial

8

**Correlación
Canónica**

12

**Análisis de
Correspondencias**

17

**Escalamiento
Multidimensional**

19

Análisis Clúster

21

**Análisis
Discriminante**

24

MANOVA

26

**Código de Análisis de
Componentes
Principales**

30

**Código de
Análisis Factorial**

35

**Código de
Correlación
Canónica**

43

**Código de Análisis de
Correspondencias**

48

**Código de
Escalamiento
Multidimensional**

52

**Código de Análisis
Clúster**

58

**Código de Análisis
Discriminante**

67

**Código de
MANOVA**

Análisis de Componentes Principales

El Análisis de Componentes Principales conocido como (PCA) es una técnica estadística multivariada que transforma un conjunto de variables originales posiblemente correlacionadas, en un nuevo conjunto de variables no correlacionadas llamadas componentes principales.

Su objetivo es reducir la dimensionalidad de los datos con la mínima pérdida posible de información.

En este caso vamos a aplicar el Análisis de componentes principales a la base airquality que ya está precargada en R.

Como sabemos la calidad de aire es un factor determinante en la salud pública y en las condiciones ambientales de una región. Hay diversos contaminantes atmosféricos, como el ozono, la radiación solar, la velocidad del viento y la temperatura, ya que influyen de manera conjunta en los niveles de contaminación.

La base de datos airquality contiene mediciones diarias tomadas en la ciudad de Nueva York durante el año de 1973, e incluye variables que describen aspectos fundamentales del ambiente atmosférico.

Aplicar el Análisis de Componentes Principales (ACP) a la base airquality permite:

- Reducir la información de cuatro variables a uno o dos componentes que expliquen la mayor parte de la variación.
- Identificar las combinaciones lineales de variables que mejor describen el comportamiento atmosférico.
- Construir un índice ambiental basado en el primer componente principal, útil para comparar días o clasificar condiciones del aire.

Objetivo:

Es construir un índice ambiental basado en el primer componente principal utilizando la base, con el fin de ver el comportamiento en conjunto de las principales variables de calidad del aire.

Base de datos:

153 observaciones de mediciones diarias

4 variables numéricas relacionadas con la calidad del aire

- Ozone: Concentración del Ozono
- Solar.R: Radiación solar
- Wind: Velocidad del viento
- Temp: Temperatura

El primer componente principal explica aproximadamente 70–75% de la variabilidad total y los dos componentes explica más del 90% de la variabilidad.


Tabla 1

	Componente 1	Componente 2	Componente 3	Componente 4
Ozone	0.589		0.115	0.797
Solar.R	0.317	-0.898	-0.278	-0.123
Wind	-0.497	-0.430	0.691	0.302
Temp	0.553		0.658	-0.508

FUENTE: ELABORACIÓN PROPIA

FIGURA 1


varianza explicada por componentes



FUENTE: ELABORACIÓN PROPIA

FIGURA 2


porcentaje de varianza explicada por componentes principales



FUENTE: ELABORACIÓN PROPIA

FIGURA 3


BIPLLOT DE COMPONENTES PRINCIPALES



FUENTE: ELABORACIÓN PROPIA

FIGURA 4


CÍRCULO DE CORRELACIONES DE VARIABLES POR CONTRIBUCIÓN A LAS DIMENSIONES



FUENTE: ELABORACIÓN PROPIA

FIGURA 5


CÍRCULO DE CORRELACIONES DE VARIABLES POR CALIDAD DE REPRESENTACIÓN



FUENTE: ELABORACIÓN PROPIA

FIGURA 6

ÍNDICES DE VULNERABILIDAD



Resume el comportamiento conjunto de las condiciones atmosféricas. Facilita clasificar los días en niveles como:

- Muy Baja
- Baja
- Media
- Alta
- Muy Alta

según el valor obtenido y su posición.

FUENTE: ELABORACIÓN PROPIA

Análisis Factorial

El análisis factorial conocido también como (AF) es una técnica multivariada que sirve para reducir un conjunto grande de variables a un número pequeño de factores que explican la mayor parte de la variabilidad en los datos.

En otras palabras, buscamos agrupar variables que están altamente correlacionadas entre sí y encontrar factores “ocultos” que las explican.

En este Método vamos a usar la base de datos de las calificaciones de los alumnos de una secundaria, ya que, dentro del ámbito educativo, el desempeño académico es un elemento fundamental para comprender el proceso de aprendizaje de los estudiantes, así como los factores que influyen en sus resultados.

En el contexto del Análisis Factorial se presenta como una técnica para identificar variables no observables dentro de los datos académicos. La base de datos utilizada contiene información del desempeño de 30 estudiantes en cinco materias clave del currículo básico. Este conjunto de datos permite analizar si las materias comparten un componente común que pueda explicar la mayor parte de la variabilidad observada.

Objetivo:

Es identificar los factores latentes que explican la variabilidad del desempeño académico de los estudiantes, con el fin de simplificar el análisis, mejorar la comprensión de las relaciones entre asignaturas y aportar información útil para evaluación educativa.

Base de datos:

30 observaciones de estudiantes

6 variables

- Matemáticas
- Español
- Historia
- Ciencias
- Ingles
- Factor: Que es el que resumen el rendimiento académico global de cada alumno.

Tabla 2


cargas de las variables

Variable	No Rotado		Varimax		Promax		Quartimax	
	1	2	1	2	1	2	1	2
Matemáticas	0.95	0.28	0.52	0.85	0.10	0.91	0.98	-0.16
Español	0.98	-0.18	0.85	0.52	0.92	0.09	0.95	0.30
Historia	0.93	0.25	0.53	0.81	0.14	0.84	0.96	-0.13
Ciencias	0.94	-0.03	0.72	0.61	0.63	0.34	0.93	0.15
Ingles	0.94	0.23	0.55	0.80	0.19	0.81	0.96	-0.10
Factor	0.98	0.13	0.64	0.75	0.39	0.64	0.99	0.00

Fuente: Elaboración propia

Figura 7


Matriz de correlaciones: sí existe estructura latente



Fuente: Elaboración propia

Figura 8


Scree Plot



Fuente: Elaboración propia

Figura 9

Diagrama Factorial (Promax)



Fuente: Elaboración propia

Correlación Canónica

El Análisis de Correlación Canónica (ACC) es utilizado para descubrir, identificar y cuantificar la asociación o relación lineal entre dos grupos de variables.

En este método vamos a usar una base de datos sobre pacientes y su salud en el ámbito de la psicología de la salud es común analizar la percepción de cada paciente a través de sus ámbitos que tienen cada uno.

En base a la técnica de Correlación Canónica en el entorno realista a través de la base de datos de los pacientes, nos permite estudiar la relación entre dos conjuntos de variables.

Objetivo:

Es evaluar la relación entre variables clínicas y sus hábitos, mediante un análisis de correlación canónica.

Base de datos:


40 observaciones de pacientes

8 variables

- Sistólica
- Glucosa
- Colesterol
- IMC
- Actividad
- Sueño
- Alcohol
- Estrés

FIGURA 10

correlación entre grupos de variables



El análisis muestra que variables como actividad física y sueño se asocian positivamente con la cognición, mientras que el estrés y el alcohol tienden a relacionarse con mayor IMC. Estas correlaciones sugieren que los hábitos saludables impactan favorablemente en la salud física y mental. Promover el sueño adecuado y la actividad física podría ser clave para mejorar el bienestar integral.

FUENTE: ELABORACIÓN PROPIA

Tabla 3

correlación importante

Grupo 1	Correlación	Grupo 2	Correlación
Sistólica	-0.9958902	Actividad	0.9966643
Glucosa	-0.9933663	Sueño	0.9773254
Colesterol	-0.9968539	Alcohol	-0.9981640
IMC	-0.9966047	Estrés	-0.9982528

Fuente: Elaboración propia


correlación canónicas

Primera	Segunda	Tercera	Cuarta
0.99466084	0.52268795	0.30840085	0.02849038

Fuente: Elaboración propia

Figura 11

Pesos de correlaciones canónicas por dimensión



La primera dimensión concentra la mayor parte de la relación entre los conjuntos de variables, por lo que es la más relevante para el análisis. Las siguientes dimensiones aportan información adicional, pero con menor fuerza explicativa. Esto muestra que el modelo canónico está capturando la esencia de la relación principalmente en el primer componente.

Fuente: Elaboración propia

Tabla 4

LAMBDA DE WILKS

Agrupación	Lambda	F aproximado	DF1	DF2	p.valor
1 a 4	0.006998382	24.27977495	16	95.34419	0.0000000
2 a 4	0.657136995	1.63250323	9	78.03020	0.1205601
3 a 4	0.904154415	0.85252347	4	66.00000	0.4971829
4 a 4	0.999188298	0.02762028	1	34.00000	0.8689891

Fuente: Elaboración propia

Tabla 5


PESOS CANÓNICOS DE LA PRIMERA CORRELACIÓN CANÓNICA

Primer componente		Segundo Componente	
Variable	Peso	Variable	Peso
Sistólica	-0.2521648	Actividad	0.3052019
Glucosa	-0.2385167	Sueño	-0.0305373
Colesterol	-0.1376824	Alcohol	-0.2809241
IMC	-0.3759644	Estrés	-0.4460320

Fuente: Elaboración propia

Figura 12


RELACIÓN ENTRE LOS SCORES DEL PRIMER PAR CANÓNICO



Fuente: Elaboración propia

FIGURA 13

RELACIÓN ENTRE LOS SCORES DEL SEGUNDO PAR CANÓNICO




FUENTE: ELABORACIÓN PROPIA

El primer par de variables canónicas captura una relación significativa y coherente entre los dos grupos, lo que valida el uso de análisis de correlación canónica para explorar sus vínculos.

Este segundo componente aporta información adicional, pero con menor fuerza explicativa. Es útil para explorar matices en la relación entre los grupos, aunque el vínculo principal se encuentra en el primer par.

FIGURA 14

BIPLLOT DE ANÁLISIS DE CORRELACIÓN CANÓNICA



La dispersión de los puntos muestra cómo se distribuyen los individuos en función de sus perfiles combinados. Si hay agrupamientos, podrían indicar patrones comunes de salud.

FUENTE: ELABORACIÓN PROPIA

Análisis de Correspondencias

Es una técnica multivariante para estudiar las relaciones de dependencia entre variables categóricas (cualitativas), a partir de una tabla de contingencias.

El principal propósito de este tipo de análisis es transformar una tabla con información numérica en una representación gráfica que facilite la interpretación de la información, buscando unos ejes o dimensiones (variables hipotéticas) que expliquen la distancia de las frecuencias.

En este método vamos a utilizar una base de datos sobre tipos de alcohol y la experiencia de las personas que han tenido al consumirlo, contar con un análisis detallado de la percepción del consumidor hacia diferentes bebidas alcohólicas tiene diversas aplicaciones, tales como mejorar la formulación de productos, analizar la aceptación en el mercado y estudiar diferencias en preferencias entre grupos de consumidores.

Objetivo

Analizar y visualizar las asociaciones entre los distintos tipos de bebidas alcohólicas evaluadas y las calificaciones sensoriales que recibieron, mediante un Análisis de Correspondencias que permita identificar patrones, agrupaciones y relaciones relevantes dentro del conjunto de datos.

Base de datos:

60 observaciones de consumidores


5 variables

- Calificación: valoración cualitativa otorgada a la bebida (Malo, Regular, Bueno, Muy Bueno, Excelente).
- Alcohol_A: puntuación cuantitativa sensorial de la bebida A.
- Alcohol_B: puntuación de la bebida B.
- Alcohol_C: puntuación de la bebida C.
- Alcohol_D: puntuación de la bebida D.

FIGURA 15

NUBE DE PUNTOS DE INDIVIDUOS


Las dimensiones Dim1 (36.4%) y Dim2 (14%) explican en conjunto el 50.4% de la variabilidad, lo cual es razonable para el Análisis de Correspondencia. Esto sugiere que el plano es útil para visualizar diferencias entre individuos.



FUENTE: ELABORACIÓN PROPIA

FIGURA 16


NUBE DE PUNTOS DE LAS CATEGORÍAS



FUENTE: ELABORACIÓN PROPIA

FIGURA 17


NUBE DE PUNTOS DE INDIVIDUOS Y CATEGORÍAS



FUENTE: ELABORACIÓN PROPIA

FIGURA 18

Cos2 de Las categorías en Las primeras dos Dimensiones




Fuente: Elaboración propia

Las primeras dos dimensiones permiten distinguir claramente las valoraciones positivas y negativas del alcohol, mostrando categorías bien representadas y con contribuciones relevantes. En conjunto, los individuos y variables suplementarias forman patrones coherentes que confirman perfiles consistentes en la percepción del alcohol.

FIGURA 19


Contribución de Las categorías en Las primeras dos Dimensiones



Fuente: Elaboración propia

FIGURA 20


NUBE DE PUNTOS DE LAS categorías (cos2 mayor a .4)



FUENTE: ELABORACIÓN PROPIA

FIGURA 21


NUBE DE PUNTOS DE INDIVIDUOS Y categorías (cos2 mayor a .4)



FUENTE: ELABORACIÓN PROPIA

FIGURA 22

NUBE DE PUNTOS DE VARIABLES SUPLEMENTARIAS Y CATEGORÍAS (COS2 MAYOR A .4)



FUENTE: ELABORACIÓN PROPIA

El mapa factorial revela que las valoraciones Muy Altas de los alcoholes A, B y C se agrupan en la parte superior del plano, indicando una asociación fuerte y consistente entre sí. En contraste, las valoraciones Bajas y Medias se concentran hacia el lado derecho del eje 1, mostrando un patrón opuesto. Las categorías suplementarias también confirman estas tendencias: las percepciones “Excelente” y “Bueno” se asocian a niveles altos, mientras que “Regular” y “Malo” se vinculan a niveles bajos, reforzando la coherencia del análisis de correspondencia.

Escalamiento Multidimensional

Este método es otra de las técnicas estadísticas multivariante. Su mayor aplicación es en marketing y en las ciencias sociales.

Proceso: a través de los datos considera las preferencias y percepciones de los participantes, esto ocurre al calcular una matriz de distancias o de similitudes entre individuos buscando representarlos en un diagrama visual, es decir, grafica las distancias, de tal forma que se pueda observar la tendencia o el patrón que siguen los individuos.

Escala: si los datos son continuos la matriz es de distancias y si los datos son cualitativos la matriz es de similitudes

En este caso vamos a aplicar el Escalamiento Multidimensional a la base mtcars que ya está precargada en R.

En la industria automotriz, existe un esfuerzo constante para buscar un modelo de vehículo que logre un equilibrio entre eficiencia, rendimiento y funcionalidad. Debido a la gran diversidad de atributos, surge la necesidad de comparar modelos de autos para entender cómo se relacionan entre sí, considerando factores como el desempeño, el consumo, el peso, la potencia, entre otros.

Objetivo:

Analizar las relaciones entre los distintos modelos de automóviles presentes en la base de datos mtcars, considerando variables como rendimiento, potencia, peso, número de cilindros, entre otras, mediante la aplicación de Escalamiento Multidimensional.

Base de datos


32 observaciones (modelos de coche 1973 – 1974)

5 variables

- mpg: Eficiencia de combustible
- disp: Cilindrada del motor en pulgadas cúbicas
- drat: Relación del eje trasero
- wt: Peso del coche en miles de libras

FIGURA 23

DIAGRAMA DE SHEPARD




FUENTE: ELABORACIÓN PROPIA

Como se puede observar, las distancias originales frente a las distancias en el espacio MDS siguen una tendencia lineal clara. Además, un valor de RSQ de 0.9899, cercano a 1, indica que el escalamiento multidimensional captura muy bien la variabilidad de los datos originales.

FIGURA 24

MAPA DE ESCALAMIENTO MULTIDIMENSIONAL



FUENTE: ELABORACIÓN PROPIA

En la figura anterior podemos distinguir tres agrupaciones de modelos de autos:

Grupo 1: Conformado por Chrysler Imperial, Lincoln Continental y Cadillac Fleetwood, localizados en la parte inferior derecha. Caracterizado por valores altos en la dimensión 1 y valores bajos en la dimensión 2.

Grupo 2: Conformado por Honda Civic, Toyota Corolla, Fiat 128, Lotus Europa, Fiat X1-9 y Porsche 914-2, localizados en la parte izquierda. Caracterizados por valores bajos en dimensión 1.

Grupo 3: Conformado por el resto de los modelos de autos, localizado en medio del gráfico.

Caracterizados con valores medios en la dimensión 1 (posiblemente pueda ser dividido en dos grupos).

Grupo 1: Tienen baja eficiencia de combustible, motores con gran cilindrada y un gran peso. En general son autos de lujo grandes y pesados.

Grupo 2: Son autos compactos, ligeros y con buen rendimiento de combustible.

Grupo 3: Autos más heterogéneos con gran espectro de vehículos que no son pequeños y eficientes, pero tampoco grandes y lujosos.

Análisis Clúster

Análisis Clúster también conocida como técnica de agrupación que produce clasificaciones a partir de datos que no están clasificados y como la mayoría de las técnicas multivariantes se tiene un conjunto de n individuos caracterizado por p -variables.

En este método vamos a utilizar una base de datos de cráneos de Jaguares dada que la variabilidad natural entre los jaguares, la interpretación de cada cráneo resulta limitada, incluso contando con múltiples mediciones morfológicas. En este contexto, agrupar cráneos con características semejantes permite sintetizar la información de manera más eficiente, revelando tendencias que no son evidentes a simple vista. Una herramienta adecuada para este tipo de análisis es el Análisis Clúster.

Objetivos:

Agrupar diferentes cráneos de jaguares en función de sus características mediante la aplicación del Análisis Clúster, con el fin de identificar perfiles morfológicos y posibles patrones dentro de la población estudiada.

Base de datos:


32 observaciones de cráneos

6 variables

- Longitud: Medida total del cráneo
- Anchura : Amplitud lateral del cráneo
- Altura: Dimensión vertical principal
- AltCara: Altura de la región facial
- AncCara: Anchura de la región facial
- Tipo: Clasificación

FIGURA 25

MÉTODO DEL CODO




El número óptimo de clústeres para los cráneos de jaguares es 3, de acuerdo con el método del codo.

Esto sugiere que en la morfología craneométrica de los jaguares analizados existen tres perfiles morfológicos diferenciados.

FUENTE: ELABORACIÓN PROPIA

FIGURA 26

Dendrograma




FUENTE: ELABORACIÓN PROPIA

Igual revelado como el anterior grafico revela la existencia de tres grupos morfológicos bien diferenciados, definidos por un umbral de disimilitud de aproximadamente 5.0. Esta segmentación sugiere que los cráneos presentan patrones estructurales consistentes dentro de cada grupo. La clara separación entre los clusters indica que la variabilidad interna es menor que la variabilidad entre grupos, lo que respalda la validez de esta clasificación.

FIGURA 27

MAPA DE CALOR DE LAS DISTANCIAS EUCLIDIANAS



Análisis Discriminante

El Análisis Discriminante es una técnica estadística utilizada para clasificar individuos en grupos y determinar qué variables explican mejor la diferencia entre esos grupos.

En este método vamos a utilizar la base de datos de penguins que ya esta precargada en R que contiene información sobre diferentes especies de Pingüinos, que se clasifican en tres grupos como Adelie, Chinstrap y Gentoo. Aunque tengamos la clasificación de especies, no disponemos de un modelo estadístico que nos permita predecir nuevas observaciones basadas en características físicas, así que es necesario identificar variables que permitan discriminar entre las especies y construir un modelo de análisis discriminante apropiado.

Objetivo:

Construir un modelo de análisis discriminante que clasifique de forma efectiva las observaciones en sus respectivas especies.

Base de datos:


344 observaciones (pingüinos de las especies Adelie, Chinstrap y Gentoo).

5 variables:

- bill_length_mm: Longitud del pico en mm
- bill_depth_mm: Profundidad del pico en mm
- flipper_length_mm: Longitud de la aleta en mm
- body_mass_g: Masa corporal en gramos
- species: Especie del pingüino (Adelie, Chinstrap, Gentoo)

FIGURA 28

DISTRIBUCIONES DE LOS CLÚSTERES




FUENTE: ELABORACIÓN PROPIA

En la figura anterior, se puede observar que en todas las distribuciones de densidad de cada variable que hay se logra observar que hay una separación parcial entre las categorías. Esto indica que son adecuadas para el análisis discriminante.

FIGURA 29

GRÁFICO DE DISPERSIÓN POR CLÚSTERES



FUENTE: ELABORACIÓN PROPIA

El gráfico revela que las especies de pingüinos presentan patrones morfológicos claramente diferenciables, lo que permite agruparlas en clústeres bien definidos según sus características físicas. Variables como la longitud y profundidad del pico, la longitud de la aleta y la masa corporal muestran relaciones significativas entre sí y permiten distinguir especies con bastante precisión.

TABLA 6

FUNCIONES DISCRIMINANTES

	LD1	LD2
Bill_length_mm	-0.4822268	-2.28140108
Bill_depth_mm	2.0484627	-0.04148024
Flipper_length_mm	-1.2115969	0.18947709
Body_mass_g	-1.0421560	1.37249348

FUENTE: ELABORACIÓN PROPIA

LD1: Diferencia especies con picos más profundos frente a aquellas con cuerpos más grandes y aletas más largas y LD2: Contrasta longitud del pico con masa corporal.

TABLA 7

MATRIZ DE CONFUSIÓN

Real		Predicho		
		Adelie	Chinstrap	Gentoo
1	Adelie	150	1	0
2	Chinstrap	3	65	0
3	Gentoo	0	0	123

FUENTE: ELABORACIÓN PROPIA


El modelo distingue muy bien entre las tres especies de pingüinos.

Gentoo es la especie más fácil de identificar: 0 errores.

La confusión entre Adelie y Chinstrap sugiere que estas dos especies tienen características morfológicas más similares, lo que puede dificultar su separación.

FIGURA 30

LÍMITES DE DECISIÓN



FUENTE: ELABORACIÓN PROPIA

MANOVA

La técnica de análisis de varianza multivariado (MANOVA) es una extensión del análisis de varianza tradicional (ANVA) que permite el comparar medias en múltiples variables dependientes, tomando en cuenta su relación. Es adecuada cuando las variables respuestas están correlacionadas brindando un panorama más completo de los efectos de un factor categórico sobre un conjunto de variables dependientes.

En este método vamos a utilizar la base de datos de penguins que ya está precargada en R que son especies de pingüinos (Adelie, Chinstrap y Gentoo) presentan diferencias visibles en características morfológicas como longitud del pico, profundidad del pico, longitud de aletas y masa corporal, se requiere corroborar si estas diferencias multivariadas entre especies son estadísticamente significativas. Dado que estas variables probablemente están correlacionadas, es necesario evaluar las diferencias de manera conjunta, siendo el uso de MANOVA apropiado para este caso.

Objetivo:

Aplicar un MANOVA para determinar si las diferencias morfológicas entre las especies de pingüinos (Adelie, Chinstrap y Gentoo) son estadísticamente significativas considerando de manera conjunta las variables morfológicas: longitud del pico, profundidad del pico, longitud de aletas y masa corporal.

Base de datos:


344 observaciones completas

5 variables:

- bill_length_mm: Longitud del pico (mm)
- bill_depth_mm: Profundidad del pico (mm)
- flipper_length_mm: Longitud de las aletas (mm)
- body_mass_g: Masa corporal en gramos
- species: Especie (Adelie, Chinstrap, Gentoo)

FIGURA 31

COMPARACIÓN DE LAS VARIABLES POR CLÚSTERES




FUENTE: ELABORACIÓN PROPIA

Como se observa en la figura anterior los gráficos de cajas de los diferentes clústeres en las mismas variables no hay traslape significativo entre ellas, lo que nos indica que hay separación estructural entre especies.


FIGURA 32

CORRELACIONES DE LAS VARIABLES DENTRO DE LOS CLÚSTERES


Correlaciones Adelie



Correlaciones Chinstrap



Correlaciones Gentoo



FUENTE: ELABORACIÓN PROPIA

Se observa que las variables morfológicas de los pingüinos presentan correlaciones internas dentro de cada especie. El MANOVA realizado sobre las variables bill_length_mm, bill_depth_mm, flipper_length_mm y body_mass_g arrojó una lambda de Wilks = 0.0188, con un estadístico $F(8, 672) = 528.87$ y un p-valor $< 2.2e-16$. Esto indica evidencia altamente significativa para rechazar la hipótesis nula de igualdad multivariada, confirmando que las especies de pingüinos difieren de manera conjunta en sus características morfológicas.

Dado que el MANOVA rechaza la hipótesis nula, se procedió a realizar ANOVAs individuales para cada variable. Los resultados fueron los siguientes:

- bill_length_mm: $F(2, 339) = 410.6$, $p < 2.2e-16$
- bill_depth_mm: $F(2, 339) = 359.79$, $p < 2.2e-16$
- flipper_length_mm: $F(2, 339) = 594.8$, $p < 2.2e-16$
- body_mass_g: $F(2, 339) = 343.63$, $p < 2.2e-16$

CÓDIGO DE ANALISIS DE COMPONENTES PRINCIPALES

```
# =====  
  
#  ANÁLISIS DE COMPONENTES PRINCIPALES CON AIRQUALITY  
  
# =====  
  
# Cargar datos  
data("airquality")  
  
# Eliminamos valores NA  
air <- na.omit(airquality)  
  
# Selección de variables numéricas  
data_raw <- air[, c("Ozone", "Solar.R", "Wind", "Temp")]  
  
# Estandarización  
air_std <- as.data.frame(scale(data_raw))  
  
# -----  
# MATRIZ DE CORRELACIÓN Y ADECUACIÓN DEL PCA  
# -----  
  
MR <- cor(air_std)  
det(MR)  
  
library(psych)  
cortest.bartlett(MR, nrow(air_std))  
KMO(MR)  
  
# -----  
# ANÁLISIS DE COMPONENTES PRINCIPALES (ACP)  
# -----
```

```

compo <- princomp(air_std)

summary(compo)

loadings(compo)

# Scree plot
plot(compo, main="Scree Plot - airquality")

# Biplot
biplot(compo)

# ACP con prcomp
acpcor <- prcomp(air_std)

# -----
# ANÁLISIS VISUAL CON FACTOEXTRA
# -----

library(factoextra)

fviz_eig(acpcor, addlabels = TRUE, ylim = c(0, 80))
fviz_pca_var(acpcor, col.var = "cos2")
fviz_pca_var(acpcor, col.var = "contrib")

# -----
# CÁLCULO DEL ÍNDICE (1er componente)
# -----

# Cargas del primer componente
cp1 <- compo$loadings[, 1]

```

```

# Valores del primer componente

Indice <- as.vector(as.matrix(air_std) %*% cp1)


# Añadir índice a la base

air_std$Indice <- Indice


# -----

# ORDENAR Y CLASIFICAR — CORREGIDO

# -----


Ciudad <- rownames(air_std)

Num_obs <- seq(1:nrow(air_std))


datt <- data.frame(Ciudad, Num_obs, Indice)

Ino <- datt[order(datt$Indice), ]


# Clasificación REAL en 5 niveles por cuantiles

breaks <- quantile(Ino$Indice, probs = seq(0, 1, length.out = 6))


Ino$Clasi <- cut(Ino$Indice,
               breaks = breaks,
               include.lowest = TRUE,
               labels = c("MB", "B", "M", "A", "MA"))


# Regresar al orden original para graficar

dattor <- Ino[order(Ino$Num_obs), ]


# -----

# GRÁFICO FINAL DEL ÍNDICE — CORREGIDO

# -----

```

```
library(ggplot2)

ggplot(dattor, aes(x = Num_obs, y = Indice, label = Ciudad)) +
  geom_point(aes(col = Clasi), size = 3) +
  geom_text(hjust = 1, size = 2) +
  labs(
    subtitle = "Índice construido con el Primer Componente Principal",
    title = "Índice PCA - Base airquality",
    caption = "Fuente: Elaboración propia"
  ) +
  theme_minimal()
```

CÓDIGO DE ANÁLISIS FACTORIAL

```
# =====  
# ANÁLISIS FACTORIAL - CALIFICACIONES SECUNDARIA  
# =====  
  
# 1. Cargar librerías -----  
library(psych)  
library(ggcorrplot)  
library(MVN)  
library(readxl)  
  
# 2. Cargar archivo Excel -----  
alumnos_raw <- read_excel("C:/Users/pavis/Downloads/alumnos .xlsx")  
  
message("Base cargada correctamente:")  
print(head(alumnos_raw))  
  
# 3. Mantener solo variables numéricas -----  
# Si existe columna Alumno, eliminarla  
if ("Alumno" %in% colnames(alumnos_raw)) {  
  alumnos_raw$Alumno <- NULL  
}  
  
# Mantener solo columnas numéricas  
alumnos <- alumnos_raw[, sapply(alumnos_raw, is.numeric)]  
  
message("Variables consideradas en el AFE:")  
print(colnames(alumnos))  
  
n <- nrow(alumnos)  
p <- ncol(alumnos)
```

```
message(paste("\nLa base tiene", n, "observaciones y", p, "variables numéricas."))
```

```
# 4. Normalidad Multivariada (compatible con cualquier MVN) -----
```

```
message("\n--- Normalidad Multivariada (Automática - MVN) ---")
```

```
normalidad <- mvn(alumnos)
```

```
# Mostrar normalidad multivariada si existe
```

```
if (!is.null(normalidad$multivariateNormality)) {
```

```
  print(normalidad$multivariateNormality)
```

```
} else {
```

```
  print("Tu versión del paquete MVN no incluye multivariateNormality. Se calculó normalidad univariada.")
```

```
}
```

```
# 5. Matriz de correlaciones -----
```

```
mat_cor <- cor(alumnos)
```

```
message("\n--- Matriz de correlaciones ---")
```

```
print(round(mat_cor, 2))
```

```
ggcorrplot(mat_cor, type = "lower", lab = TRUE,
```

```
  title = "Matriz de Correlaciones - Calificaciones")
```

```
# 6. Pruebas de factorizabilidad -----
```

```
message("\n--- Prueba de Bartlett ---")
```

```
print(cortest.bartlett(mat_cor, n = n))
```

```
message("\n--- Medida KMO ---")
```

```
print(KMO(mat_cor))
```

7. Scree y análisis paralelo -----

```
message("\n--- Scree Plot ---")
```

```
scree(mat_cor, main = "Scree Plot - Calificaciones")
```

Número de factores sugerido

```
num_factores <- 2
```

8. AFE -----

```
message("\n--- AFE sin rotación ---")
```

```
fa_none <- fa(r = mat_cor, nfactors = num_factores,
```

```
    rotate = "none", fm = "ml")
```

```
print(fa_none)
```

```
message("\n--- AFE Varimax ---")
```

```
fa_varimax <- fa(r = mat_cor, nfactors = num_factores,
```

```
    rotate = "varimax", fm = "ml")
```

```
print(fa_varimax)
```

```
message("\n--- AFE Promax ---")
```

```
fa_promax <- fa(r = mat_cor, nfactors = num_factores,
```

```
    rotate = "promax", fm = "ml")
```

```
print(fa_promax)
```

```
message("\n--- AFE Quartimax ---")
```

```
fa_quartimax <- fa(r = mat_cor, nfactors = num_factores,
```

```
    rotate = "quartimax", fm = "ml")
```

```
print(fa_quartimax)
```

9. Residuales -----

```
message("\n--- Residuales (Varimax) ---")
```

```
print(round(fa_varimax$residual, 3))
```

```

# 10. Cargas factoriales -----
message("\n--- Cargas Factoriales Varimax ( $\geq 0.30$ ) ---")
print(fa_varimax$loadings, cutoff = 0.30)

# 11. Diagrama Factorial -----
fa.diagram(fa_promax,
  main = paste("Diagrama Factorial -", num_factores, "factores (Promax)"))

# 12. Comparación de rotaciones -----
message("\n--- Comparación de rotaciones ---")
print(data.frame(
  Varimax = round(fa_varimax$loadings[, 1:num_factores], 2),
  Promax = round(fa_promax$loadings[, 1:num_factores], 2),
  Quartimax = round(fa_quartimax$loadings[, 1:num_factores], 2),
  No_Rotado = round(fa_none$loadings[, 1:num_factores], 2)
))

# 13. Biplots -----
if (num_factores >= 2) {

  par(mar=c(4,4,2,1))
  par(mfrow = c(2, 2))

  rotaciones <- c("none", "varimax", "quartimax", "promax")

  for (r in rotaciones) {
    modelo_temp <- fa(r = mat_cor, nfactors = 2, rotate = r, fm = "ml")
    fa.plot(modelo_temp, main = paste("Rotación:", r))
  }
}

```

```
par(mfrow = c(1, 1))  
}
```

CÓDIGO DE CORRELACIÓN CANÓNICA

```
# =====  
# CORRELACIÓN CANÓNICA OPTIMIZADA - SALUD PACIENTES  
# =====  
  
# --- LIBRERÍAS ---  
library(readxl)  
library(CCA)  
library(CCP)  
library(fields)  
library(ggplot2)  
library(tidyr)  
library(dplyr)  
library(psych)  
  
# --- CARGAR DATOS ---  
datos <- read_excel("C:/Users/pavis/Downloads/pacientes_salud.xlsx")  
  
# --- DEFINIR GRUPOS ---  
vars_g1 <- c("Sistólica","Glucosa","Colesterol","IMC") # Variables clínicas  
vars_g2 <- c("Actividad","Sueño","Alcohol","Estrés") # Hábitos  
  
# Verificación de existencia de columnas  
missing_g1 <- setdiff(vars_g1, colnames(datos))  
missing_g2 <- setdiff(vars_g2, colnames(datos))  
if(length(missing_g1) > 0 || length(missing_g2) > 0){  
  stop(paste0("Faltan columnas:\nGrupo 1: ", paste(missing_g1, collapse = ", "),  
    "\nGrupo 2: ", paste(missing_g2, collapse = ", ")))  
}  
  
# Selección de grupos
```

```

grupo1 <- datos[, vars_g1]
grupo2 <- datos[, vars_g2]

# --- Conversión a numérico ---
to_numeric_safely <- function(df){
  df[] <- lapply(df, function(x){
    if(!is.numeric(x)) suppressWarnings(as.numeric(x)) else x
  })
  return(df)
}

grupo1 <- to_numeric_safely(grupo1)
grupo2 <- to_numeric_safely(grupo2)

# --- Eliminación conjunta de NA ---
idx_complete <- complete.cases(grupo1, grupo2)
grupo1 <- grupo1[idx_complete, , drop = FALSE]
grupo2 <- grupo2[idx_complete, , drop = FALSE]

cat("Filas conservadas tras eliminación conjunta de NA:", sum(idx_complete), "\n")

# =====
#   NORMALIDAD UNIVARIANTE
# =====

shapiro_univar <- function(df){
  apply(df, 2, function(x){
    if(length(unique(x)) > 2) shapiro.test(x)$p.value else NA
  })
}

cat("P-valores Shapiro-Wilk Grupo 1:\n")

```

```

print(shapiro_univar(grupo1))

cat("P-valores Shapiro-Wilk Grupo 2:\n")
print(shapiro_univar(grupo2))

# =====
#   DETECCIÓN DE OUTLIERS MULTIVARIADOS
# =====

detect_outliers <- function(df, alpha = 0.01){
  center <- colMeans(df)
  cov_mat <- cov(df)
  md <- mahalanobis(df, center, cov_mat)
  threshold <- qchisq(1 - alpha, df = ncol(df))
  outliers <- which(md > threshold)
  return(outliers)
}

outliers_g1 <- detect_outliers(grupo1)
outliers_g2 <- detect_outliers(grupo2)
outliers <- union(outliers_g1, outliers_g2)

if(length(outliers) > 0){
  g1_clean <- grupo1[-outliers, , drop = FALSE]
  g2_clean <- grupo2[-outliers, , drop = FALSE]
  cat("Se eliminaron los siguientes outliers (índices):\n")
  print(outliers)
} else {
  g1_clean <- grupo1
  g2_clean <- grupo2
  cat("No se detectaron outliers.\n")
}

```

```
if(nrow(g1_clean) < 3 || nrow(g2_clean) < 3){
  stop("Datos insuficientes tras limpieza para realizar CCA (se requieren al menos 3 filas).")
}
```

```
# Escalado de variables
```

```
g1_clean <- scale(g1_clean)
```

```
g2_clean <- scale(g2_clean)
```

```
cat("Datos listos para CCA. Filas restantes:", nrow(g1_clean), "\n")
```

```
# =====
```

```
#   MATRIZ DE CORRELACIONES CRUZADAS
```

```
# =====
```

```
M <- matcor(g1_clean, g2_clean)
```

```
print("Resumen de correlaciones intra y cruzadas:\n")
```

```
print(list(Xcor = M$Xcor, Ycor = M$Ycor, r = M$r))
```

```
# =====
```

```
#   CORRELACIÓN CANÓNICA
```

```
# =====
```

```
CC <- cc(g1_clean, g2_clean)
```

```
print("Correlaciones canónicas:\n")
```

```
print(CC$cor)
```

```
# --- TEST WILKS LAMBDA ---
```

```
n <- nrow(g1_clean)
```

```
p <- ncol(g1_clean)
```

```
q <- ncol(g2_clean)
```

```
test <- p.asym(CC$cor, n, p, q, tstat = "Wilks")
```

```
print("Test Wilks Lambda:\n")
```

```
print(test)
```

```
# =====
```

```
#  CORRELACIONES IMPORTANTES Y PESOS CANÓNICOS (Primer par)
```

```
# =====
```

```
# Primer par de scores canónicos
```

```
x_scores_1 <- CC$scores$xscores[, 1]
```

```
y_scores_1 <- CC$scores$yscores[, 1]
```

```
# Correlaciones con las variables originales usadas en la CCA (limpias y escaladas)
```

```
cor_X1 <- cor(g1_clean, x_scores_1)
```

```
cor_Y1 <- cor(g2_clean, y_scores_1)
```

```
# Mostrar correlaciones importantes (por ejemplo,  $|r| > 0.5$ )
```

```
cat("Correlaciones importantes del primer componente canónico (Grupo 1):\n")
```

```
print(cor_X1[abs(cor_X1) > 0.5, , drop = FALSE])
```

```
cat("Correlaciones importantes del primer componente canónico (Grupo 2):\n")
```

```
print(cor_Y1[abs(cor_Y1) > 0.5, , drop = FALSE])
```

```
# Pesos canónicos (coeficientes) del primer componente
```

```
x_weights_1 <- CC$xcoef[, 1]
```

```
y_weights_1 <- CC$ycoef[, 1]
```

```
cat("Pesos canónicos del primer componente (Grupo 1):\n")
```

```
print(x_weights_1)
```

```
cat("Pesos canónicos del primer componente (Grupo 2):\n")
```

```
print(y_weights_1)
```

```
# =====
#   VISUALIZACIONES
# =====

# Barras de correlaciones canónicas
barplot(CC$cor, xlab = "Dimensiones", ylab = "Correlaciones Canónicas",
        names.arg = seq_along(CC$cor), ylim = c(0, 1))

# Gráficos de scores (primer y segundo par)
if(ncol(g1_clean) >= 2 && ncol(g2_clean) >= 2){
  plot(CC$scores$xscores[,1], CC$scores$yscores[,1],
       xlab = "Score Grupo1 - 1", ylab = "Score Grupo2 - 1",
       main = "Primer par de variables canónicas")
  if(length(CC$cor) >= 2){
    plot(CC$scores$xscores[,2], CC$scores$yscores[,2],
         xlab = "Score Grupo1 - 2", ylab = "Score Grupo2 - 2",
         main = "Segundo par de variables canónicas")
  }
}

# --- Gráfico de correlaciones individuales ---
df_y <- grupo1 %>%
  mutate(id_row = row_number()) %>%
  pivot_longer(cols = -id_row, names_to = "Y_var", values_to = "Y_value")

df_x <- grupo2 %>%
  mutate(id_row = row_number()) %>%
  pivot_longer(cols = -id_row, names_to = "X_var", values_to = "X_value")

plot_data <- full_join(df_y, df_x, by = "id_row")
```

```

ggplot(plot_data, aes(x = X_value, y = Y_value)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = TRUE, color = "darkblue", linewidth = 0.8) +
  facet_grid(Y_var ~ X_var, scales = "free") +
  labs(title = "Correlación entre Variables del Grupo 1 y Grupo 2",
        x = "Variables del Grupo 2",
        y = "Variables del Grupo 1") +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    strip.text.x = element_text(size = 9, face = "bold"),
    strip.text.y = element_text(size = 9, face = "bold"),
    axis.title.x = element_text(size = 10, face = "bold"),
    axis.title.y = element_text(size = 10, face = "bold"),
    panel.spacing = unit(0.5, "lines")
  )

# =====

# BILOT DE CORRELACION CANONICA

# =====

X_scores <- CC$scores$xscores[,1:2]
Y_scores <- CC$scores$yscores[,1:2]

X_loadings <- CC$xcoef[,1:2]
Y_loadings <- CC$ycoef[,1:2]

scale_factor <- 2

X_loadings_scaled <- X_loadings * scale_factor
Y_loadings_scaled <- Y_loadings * scale_factor

df_scores <- data.frame(X1 = X_scores[,1], X2 = X_scores[,2],

```

```
Y1 = Y_scores[,1], Y2 = Y_scores[,2])
```

```
df_X_load <- data.frame(var = rownames(X_loadings_scaled),  
  x = X_loadings_scaled[,1], y = X_loadings_scaled[,2],  
  grupo = "X")
```

```
df_Y_load <- data.frame(var = rownames(Y_loadings_scaled),  
  x = Y_loadings_scaled[,1], y = Y_loadings_scaled[,2],  
  grupo = "Y")
```

```
df_load <- rbind(df_X_load, df_Y_load)
```

```
ggplot() +  
  geom_point(data = df_scores, aes(x = X1, y = Y1), color = "darkblue", alpha = 0.6) +  
  geom_segment(data = df_load, aes(x = 0, y = 0, xend = x, yend = y, color = grupo),  
    arrow = arrow(length = unit(0.2,"cm")), linewidth = 0.8) +  
  geom_text(data = df_load, aes(x = x*1.1, y = y*1.1, label = var, color = grupo),  
    size = 4) +  
  labs(title = "Biplot de Correlación Canónica (Primer par de variables)",  
    x = "Primer componente canónico",  
    y = "Segundo componente canónico") +  
  theme_minimal() +  
  scale_color_manual(values = c("X" = "red", "Y" = "green")) +  
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

CÓDIGO DE ANÁLISIS DE CORRESPONDENCIA

```
## LIBRERÍAS
```

```
#####
```

```
library(readxl)
```

```
library(FactoMineR)
```

```
library(factoextra)
```

```
library(dplyr)
```

```
library(ggplot2)
```

```
#####
```

```
## CARGAR DATOS
```

```
#####
```

```
datos <- read_excel("C:/Users/pavis/Downloads/calificaciones_alcohol.xlsx")
```

```
#####
```

```
## CATEGORIZAR VARIABLES
```

```
#####
```

```
datos_cat <- datos
```

```
to_cat <- function(x){
```

```
  cut(x, breaks = c(-Inf, 9, 12, 14, Inf),
```

```
      labels = c("Bajo","Medio","Alto","Muy_Alto"))
```

```
}
```

```
datos_cat$Alcohol_A <- to_cat(datos$Alcohol_A)
```

```
datos_cat$Alcohol_B <- to_cat(datos$Alcohol_B)
```

```
datos_cat$Alcohol_C <- to_cat(datos$Alcohol_C)
```

```
datos_cat$Alcohol_D <- to_cat(datos$Alcohol_D)
```

```

datos_cat$Calificación <- factor(datos_cat$Calificación)

active_vars <- c("Alcohol_A","Alcohol_B","Alcohol_C","Alcohol_D")

#####
##  MCA CON VARIABLE SUPLEMENTARIA
#####

res.mca <- MCA(datos_cat[, c("Calificación", active_vars)],
               quali.sup = 1,
               ncp = 5,
               graph = FALSE)

#####
##  1) NUBE DE PUNTOS DE INDIVIDUOS
#####

fviz_mca_ind(res.mca,
              repel = TRUE,
              title = "Nube de Puntos - Individuos") +
theme_minimal()

#####
##  2) NUBE DE PUNTOS DE CATEGORÍAS
#####

fviz_mca_var(res.mca,
              repel = TRUE,

```

```

    title = "Nube de Puntos - Categorías") +
theme_minimal()

#####

## 3) NUBE DE PUNTOS INDIVIDUOS + CATEGORÍAS

#####

fviz_mca_biplot(res.mca,
  repel = TRUE,
  title = "Nube de Puntos - Individuos y Categorías") +
theme_minimal()

#####

## 4) COS2 DE LAS CATEGORÍAS EN DIM 1 Y 2

#####

fviz_cos2(res.mca,
  choice = "var",
  axes = c(1,2),
  title = "Cos2 de Categorías (Dim 1 y 2)") +
theme_minimal()

#####

## 5) CONTRIBUCIÓN DE LAS CATEGORÍAS EN DIM 1 Y 2

#####

fviz_contrib(res.mca,
  choice = "var",

```

```

    axes = 1,

    top = 20,

    title = "Contribución Categorías en Dim 1") +
theme_minimal()

fviz_contrib(res.mca,

    choice = "var",

    axes = 2,

    top = 20,

    title = "Contribución Categorías en Dim 2") +
theme_minimal()

#####
## 6) NUBE DE CATEGORÍAS (Cos2 > .4)
#####

cos2 <- res.mca$var$cos2
vars_high_cos2 <- rownames(cos2)[cos2[,1] + cos2[,2] > 0.40]

fviz_mca_var(res.mca,

    select.var = list(name = vars_high_cos2),

    repel = TRUE,

    title = "Categorías con Cos2 > .40") +
theme_minimal()

#####
## 7) NUBE INDIVIDUOS + CATEGORÍAS (Cos2 > .4)
#####

```

```
fviz_mca_biplot(res.mca,
  select.var = list(name = vars_high_cos2),
  repel = TRUE,
  title = "Individuos + Categorías (Cos2 > .40)" +
  theme_minimal()
```

```
#####
```

```
## 8) VARIABLES SUPLEMENTARIAS + CATEGORÍAS (Cos2 > .4)
```

```
#####
```

```
fviz_mca_biplot(res.mca,
  select.var = list(name = vars_high_cos2),
  habillage = datos_cat$Calificación,
  repel = TRUE,
  title = "Variables Suplementarias + Categorías (Cos2 > .40)" +
  theme_minimal()
```

CÓDIGO DE ESCALAMIENTO MULTIDIMENSIONAL

```
# --- Análisis de Escalamiento Multidimensional ---
```

```
# 1. Cargar Librerías
```

```
library(ggplot2)
```

```
library(dplyr)
```

```
library(ggrepel)
```

```
# 2. Cargar y Explorar el Dataset `mtcars`
```

```
data(mtcars)
```

```
original_data_name <- "mtcars"
```

```
print("\n--- Carga y Exploración del Dataset ---\n")
```

```
print("Primeras 6 filas:")
```

```
print(head(mtcars))
```

```
print("\nDimensiones del dataset:")
```

```
print(dim(mtcars))
```

```
print("\nResumen estadístico:")
```

```
print(summary(mtcars))
```

```
# 3. Preparar los datos para MDS
```

```
datos_escalados <- scale(mtcars[, c("mpg", "disp", "drat", "wt")])
```

```
print("\n--- Vista Previa de Datos Escalados ---")
```

```
print(head(datos_escalados))
```

```
# 4. Matriz de Distancias
```

```
print("\n--- Calculando Matriz de Distancias ---")
```

```
dist_matrix <- dist(datos_escalados, method = "euclidean")
```

```
# 5. MDS
```

```
print("\n--- Ejecutando MDS ---")
```

```
mds_result <- cmdscale(dist_matrix, k = 2, eig = TRUE)
```

```
# 6. Resultados
```

```
mds_coords <- as.data.frame(mds_result$points)
```

```
colnames(mds_coords) <- c("Dim1", "Dim2")
```

```
mds_coords$Car_Model <- rownames(mtcars)
```

```
print("\n--- Primeras Coordenadas MDS ---")
```

```
print(head(mds_coords))
```

```
print("\n--- Eigenvalores ---")
```

```
print(mds_result$eig)
```

```
# Cálculo varianza explicada
```

```
positive_eigenvalues <- mds_result$eig[mds_result$eig > 0]
```

```
if (length(positive_eigenvalues) > 0) {
```

```
  total_positive_variance <- sum(positive_eigenvalues)
```

```
  prop_explained_dim1 <- mds_result$eig[1] / total_positive_variance
```

```
  prop_explained_dim2 <- mds_result$eig[2] / total_positive_variance
```

```
  total_explained_by_2d <- (mds_result$eig[1] + mds_result$eig[2]) / total_positive_variance
```

```
  print(paste("Varianza explicada por Dim 1:", round(prop_explained_dim1 * 100, 2), "%"))
```

```
  print(paste("Varianza explicada por Dim 2:", round(prop_explained_dim2 * 100, 2), "%"))
```

```
  print(paste("Varianza acumulada (2D):", round(total_explained_by_2d * 100, 2), "%"))
```

```
} else {
```

```

print("\nNo hay eigenvalores positivos. MDS podría no ser adecuado.")

total_explained_by_2d <- 0
}

# 7. Gráfico MDS

print("\n--- Graficando MDS ---")

ggplot(mds_coords, aes(x = Dim1, y = Dim2, label = Car_Model)) +
  geom_point(size = 3, alpha = 0.8, color = "darkgreen") +
  geom_text_repel(size = 3, color = "gray20") +
  labs(
    title = "Mapa de Escalamiento Multidimensional - mtcars",
    subtitle = paste("Varianza explicada (2D):", round(total_explained_by_2d * 100, 2), "%"),
    x = "Dimensión 1",
    y = "Dimensión 2"
  ) +
  theme_minimal() +
  coord_fixed()

# 8. Shepard Diagram + R2

print("\n--- Shepard Diagram ---")

dist_orig <- dist(datos_escalados)
dist_mds <- dist(mds_coords[, c("Dim1", "Dim2")])

d <- as.vector(dist_orig)
dhat <- as.vector(dist_mds)

shepard_df <- data.frame(Distancia_Original = d,
  Distancia_MDS = dhat)

```

```

ggplot(shepard_df, aes(x = Distancia_Original, y = Distancia_MDS)) +
  geom_point(alpha = 0.6, color = "black") +
  geom_smooth(method = "loess", color = "red", se = FALSE) +
  geom_abline(slope = 1, intercept = 0, linetype = "dashed") +
  labs(
    title = "Diagrama de Shepard",
    x = "Distancia Original",
    y = "Distancia en MDS"
  ) +
  theme_minimal()

```

```

r_sq <- cor(d, dhat)^2
print(paste("Coeficiente de determinación ( $R^2$ ):", round(r_sq, 4)))

```

9. Correlación Variables vs Dimensiones MDS

```

print("\n--- Correlación Variables vs Dimensiones MDS ---")

```

```

cor_dim1_vars <- cor(mds_coords$Dim1, datos_escalados)
cor_dim2_vars <- cor(mds_coords$Dim2, datos_escalados)

```

```

print("\nCorrelaciones con Dim 1:")
print(cor_dim1_vars)

```

```

print("\nCorrelaciones con Dim 2:")
print(cor_dim2_vars)

```

CÓDIGO DE ANÁLISIS CLÚSTER

```
# -----  
  
# --- 1. Cargar Librerías ---  
  
# -----  
  
library(readxl)  
library(car)  
library(psych)  
library(factoextra)  
library(cluster)  
library(purrr)  
library(ggplot2)  
  
# -----  
  
# --- 2. Cargar y Preparar la Base de Datos ---  
  
# -----  
  
base_original <- read_excel("C:/Users/pavis/Downloads/CRANEOS.xlsx")  
  
head(base_original)  
dim(base_original)  
  
base1 <- base_original[, sapply(base_original, is.numeric)]  
  
head(base1)  
  
# -----  
  
# --- 3. Escalamiento de los Datos ---  
  
# -----  
  
datos <- scale(base1)
```

```
head(datos)
```

```
# -----
```

```
# --- 4. Determinar Número Óptimo de Clusters ---
```

```
# -----
```

```
fviz_nbclust(x = datos, FUNcluster = kmeans, method = "wss",
```

```
  k.max = 10,
```

```
  diss = get_dist(datos, method = "euclidean"),
```

```
  nstart = 50) +
```

```
labs(title = "Método del Codo (CRANEOS)")
```

```
fviz_nbclust(x = datos, FUNcluster = kmeans, method = "silhouette",
```

```
  k.max = 10,
```

```
  diss = get_dist(datos, method = "euclidean"),
```

```
  nstart = 50) +
```

```
labs(title = "Método de la Silueta (CRANEOS)")
```

```
# -----
```

```
# --- 4.3 Clustering Jerárquico + Dendrograma ---
```

```
# -----
```

```
mat_dist_euclidean <- dist(datos, method = "euclidean")
```

```
hc_euclidean_completo <- hclust(mat_dist_euclidean, method = "complete")
```

```
fviz_dend(hc_euclidean_completo, cex = 0.6, rect = TRUE,
```

```
  main = "Dendrograma Completo (CRANEOS)",
```

```
  sub = "Elige visualmente el número de clusters")
```

```
# -----
```

```
# --- 5. Clustering K-Means ---
```

```

k_elegido_kmeans <- 3

set.seed(123)


km_clusters <- kmeans(datos, centers = k_elegido_kmeans, nstart = 50)


arres <- cbind(base1, Cluster_Kmeans = km_clusters$cluster)

head(arres)


fviz_cluster(object = km_clusters, data = datos, show.clust.cent = TRUE,
              ellipse.type = "euclid", star.plot = TRUE, repel = TRUE) +
  labs(title = paste("Clustering K-means (k=", k_elegido_kmeans, ") — CRANEOS"),
        subtitle = "Cada color representa un cluster") +
  theme_bw()


# -----
# --- 6. Clustering Jerárquico ---
# -----


k_elegido_hc_dendrograma <- 3

hc_clusters_k <- cutree(hc_euclidea_completo, k = k_elegido_hc_dendrograma)


fviz_dend(hc_euclidea_completo, k = k_elegido_hc_dendrograma,
          cex = 0.6, rect = TRUE,
          main = paste("Dendrograma (k =", k_elegido_hc_dendrograma, ") — CRANEOS")) +
  geom_hline(yintercept = 4.15, linetype = "dashed", color = "red")


fviz_cluster(list(data = datos, cluster = hc_clusters_k),
              palette = "jco",
              geom = "point",
              ellipse.type = "convex",
              ggtheme = theme_minimal(),

```

```

    main = paste("Clustering Jerárquico (k =", k_elegido_hc_dendrograma, ")") +
geom_text(aes(label = rownames(base1)), hjust = 0, vjust = 0, size = 2)

# -----
# --- 7. DIANA ---
# -----

hc_diana_result <- diana(datos)

pltree(hc_diana_result, hang = -1, cex = 0.7,
       main = "Dendrograma DIANA (CRANEOS)",
       labels = rownames(base1))

rect.hclust(hc_diana_result, k = 3, border = 2:4)

clust_diana <- cutree(hc_diana_result, k = 3)

fviz_cluster(list(data = datos, cluster = clust_diana),
             palette = "lancet",
             geom = "point",
             ellipse.type = "convex",
             ggtheme = theme_minimal(),
             main = "Clustering DIANA — CRANEOS") +
geom_text(aes(label = rownames(base1)), size = 2)

# -----
# --- 8. Matrices de Distancias ---
# -----

mat_dist_euclidean_vis <- get_dist(datos, method = "euclidean")

```

```

fviz_dist(mat_dist_euclidean_vis, lab_size = 5) +
  labs(title = "Matriz de Distancias Euclídea (CRANEOS)") +
  theme(legend.position = "none")

mat_dist_pearson <- get_dist(datos, method = "pearson")

fviz_dist(mat_dist_pearson, lab_size = 5) +
  labs(title = "1 - Correlación Pearson (CRANEOS)") +
  theme(legend.position = "none")

# -----
# --- 9. ANOVA y MANOVA ---
# -----

arres$Cluster_Kmeans_Factor <- as.factor(arres$Cluster_Kmeans)
arres_ordenado <- arres[order(arres$Cluster_Kmeans_Factor),]

variables_originales <- colnames(base1)

print("\n--- ANOVA por variable (K-means) — CRANEOS ---\n")

for (i in 1:ncol(base1)) {
  var_name <- variables_originales[i]
  anali_aov <- aov(arres_ordenado[, var_name] ~ arres_ordenado$Cluster_Kmeans_Factor)

  print(paste("\nVariable:", var_name, "\n"))
  print(summary(anali_aov))

  boxplot(arres_ordenado[, var_name] ~ arres_ordenado$Cluster_Kmeans_Factor,
    main = paste("Boxplot de", var_name),
    xlab = "Cluster", ylab = var_name)

```

```

}

print("\n--- MANOVA (K-means) — CRANEOS ---\n")

resp_manova <- as.matrix(arres_ordenado[, 1:ncol(base1)])
modelo_manova <- manova(resp_manova ~ arres_ordenado$Cluster_Kmeans_Factor)
print(summary(modelo_manova))

print("\n--- Matriz de Correlación — CRANEOS ---\n")
print(cor(base1))

# -----
# --- 10. PCA con Clusters ---
# -----

res.pca <- princomp(datos, cor = TRUE)

pca_coords <- data.frame(res.pca$scores)
pca_coords$Cluster <- as.factor(km_clusters$cluster)

ggplot(pca_coords, aes(x = Comp.1, y = Comp.2, color = Cluster)) +
  geom_point(size = 2) +
  geom_text(aes(label = rownames(base1)), hjust = 0, vjust = 0, size = 2) +
  stat_ellipse(aes(group = Cluster), type = "norm", level = 0.68) +
  labs(title = "PCA con Clusters K-means (CRANEOS)") +
  theme_minimal()

```

CÓDIGO DE ANÁLISIS DISCRIMINANTE

```
#####  
#  ANALISIS DISCRIMINANTE  
#####
```

```
library(palmerpenguins)  
library(MVN)  
library(ggplot2)  
library(ggpubr)  
library(plyr)  
library(gridExtra)  
library(scatterplot3d)  
library(MASS)  
library(biotools)  
library(klaR)
```

```
# =====  
# 1. PREPARAR LA BASE  
# =====
```

```
data(penguins)  
  
peng <- penguins[, c("bill_length_mm","bill_depth_mm",  
                    "flipper_length_mm","body_mass_g","species")]  
peng <- na.omit(peng)  
peng$species <- factor(peng$species)  
  
vars <- c("bill_length_mm","bill_depth_mm","flipper_length_mm","body_mass_g")  
  
library(MASS)
```

```
vars <- c("bill_length_mm","bill_depth_mm","flipper_length_mm","body_mass_g")
```

```
X <- peng[, vars]
```

```
# -----
```

```
# 1. NORMALIDAD UNIVARIANTE
```

```
# -----
```

```
normalidad_univar <- apply(X, 2, function(v){
```

```
  shapiro.test(v)$p.value
```

```
})
```

```
normalidad_univar
```

```
# -----
```

```
# 2. NORMALIDAD MULTIVARIADA (Mardia)
```

```
# -----
```

```
mardia_test <- function(data){
```

```
  S <- cov(data)
```

```
  S_inv <- solve(S)
```

```
  Xc <- scale(data, center = TRUE, scale = FALSE)
```

```
  n <- nrow(data)
```

```
  p <- ncol(data)
```

```
# Skewness multivariada de Mardia
```

```
b1p <- sum((Xc %*% S_inv %*% t(Xc))^3) / n^2
```

```
# Kurtosis multivariada de Mardia
```

```
di <- diag(Xc %*% S_inv %*% t(Xc))
```

```
b2p <- mean(di^2)
```

```
list(
```

```

    skewness = b1p,
    kurtosis = b2p
  )
}

mardia_result <- mardia_test(X)
mardia_result

# -----
# 3. OUTLIERS MULTIVARIADOS (Distancia Mahalanobis)
# -----

mahal <- mahalanobis(X, colMeans(X), cov(X))

# Punto de corte chi-cuadrada
cutoff <- qchisq(0.975, df = ncol(X))

outliers <- which(mahal > cutoff)

outliers
# =====

# 3.1 NORMALIDAD MULTIVARIADA POR GRUPO (sin MVN)
# =====

print("Normalidad multivariada por especie (Mardia):\n\n")

mardia_test <- function(data){
  n <- nrow(data)
  p <- ncol(data)

  # Covarianza y su inversa

```

```

S <- cov(data)
S_inv <- solve(S)

# Datos centrados
Xc <- scale(data, center = TRUE, scale = FALSE)

# Skewness multivariada de Mardia
b1p <- sum((Xc %*% S_inv %*% t(Xc))^3) / n^2

# Kurtosis multivariada de Mardia
di <- diag(Xc %*% S_inv %*% t(Xc))
b2p <- mean(di^2)

return(list(skewness = b1p, kurtosis = b2p))
}

for (grupo in levels(peng$species)) {
  print("Especie:", grupo, "\n")
  df_grupo <- peng[peng$species == grupo, vars]

  if (nrow(df_grupo) >= 8) {
    res <- mardia_test(df_grupo)
    print("Skewness multivariada:", round(res$skewness, 4), "\n")
    print("Kurtosis multivariada:", round(res$kurtosis, 4), "\n")
  } else {
    print("No se realiza test (n < 8)\n")
  }

  print("\n")
}

# =====

```

4. HOMOCEDASTICIDAD (Box M)

```
# =====
```

```
boxM(peng[, vars], peng$species)
```

```
# =====
```

5. DESCRIPTIVOS POR ESPECIE

```
# =====
```

```
for (v in vars) {  
  print(ddply(peng, "species", summarise,  
    N = length(get(v)),  
    mean = mean(get(v)),  
    sd = sd(get(v)))  
}
```

```
# =====
```

6. DISTRIBUCIONES TEÓRICAS (MEJORADAS)

```
# =====
```

```
stats <- ddply(peng, "species", summarise,  
  m1 = mean(bill_length_mm), sd1 = sd(bill_length_mm),  
  m2 = mean(bill_depth_mm), sd2 = sd(bill_depth_mm),  
  m3 = mean(flipper_length_mm), sd3 = sd(flipper_length_mm),  
  m4 = mean(body_mass_g), sd4 = sd(body_mass_g))
```

```
# Función mejorada con rango dinámico
```

```
plot_norm <- function(mean1, sd1, mean2, sd2, mean3, sd3, titulo) {  
  min_x <- min(mean1 - 4*sd1, mean2 - 4*sd2, mean3 - 4*sd3)  
  max_x <- max(mean1 + 4*sd1, mean2 + 4*sd2, mean3 + 4*sd3)
```

```

ggplot(data.frame(x = seq(min_x, max_x, length = 400)), aes(x)) +
  stat_function(fun = dnorm, args = list(mean = mean1, sd = sd1), color = "firebrick") +
  stat_function(fun = dnorm, args = list(mean = mean2, sd = sd2), color = "green3") +
  stat_function(fun = dnorm, args = list(mean = mean3, sd = sd3), color = "blue3") +
  theme_bw() +
  ggtitle(titulo) +
  theme(plot.title = element_text(hjust = 0.5))
}

```

```

p1 <- plot_norm(stats$m1[1], stats$sd1[1],
  stats$m1[2], stats$sd1[2],
  stats$m1[3], stats$sd1[3],
  "Bill Length")

```

```

p2 <- plot_norm(stats$m2[1], stats$sd2[1],
  stats$m2[2], stats$sd2[2],
  stats$m2[3], stats$sd2[3],
  "Bill Depth")

```

```

p3 <- plot_norm(stats$m3[1], stats$sd3[1],
  stats$m3[2], stats$sd3[2],
  stats$m3[3], stats$sd3[3],
  "Flipper Length")

```

```

p4 <- plot_norm(stats$m4[1], stats$sd4[1],
  stats$m4[2], stats$sd4[2],
  stats$m4[3], stats$sd4[3],
  "Body Mass")

```

```

grid.arrange(p1, p2, p3, p4, ncol = 2)

```

```

# =====

# 6-B. DENSIDADES POR ESPECIE

# =====

plot_density_lines <- function(var, nombre){
  ggplot(peng, aes_string(x = var, color = "species")) +
    geom_density(size = 1.2) +
    scale_color_manual(values = c("firebrick","green3","blue3")) +
    theme_bw() +
    ggtitle(nombre) +
    theme(plot.title = element_text(hjust = 0.5))
}

grid.arrange(
  plot_density_lines("bill_length_mm", "Bill Length"),
  plot_density_lines("bill_depth_mm", "Bill Depth"),
  plot_density_lines("flipper_length_mm", "Flipper Length"),
  plot_density_lines("body_mass_g", "Body Mass"),
  ncol = 2
)

# =====

# 7. MATRICES DE DISPERSIÓN Y 3D

# =====

pairs(peng[, vars],
      col = c("firebrick", "green3", "blue3")[peng$species],
      pch = 19)

scatterplot3d(
  peng$bill_length_mm, peng$bill_depth_mm, peng$flipper_length_mm,

```

```

color = c("firebrick","green3","blue3")[peng$species],
pch = 19, grid = TRUE,
xlab = "Bill length", ylab = "Bill depth", zlab = "Flipper length"
)

```

```

# =====

```

```

# 8. ESTANDARIZAR VARIABLES (RECOMENDADO)

```

```

# =====

```

```

peng_scaled <- peng
peng_scaled[, vars] <- scale(peng[, vars])

```

```

# =====

```

```

# 9. AJUSTAR MODELO LDA

```

```

# =====

```

```

modelo_lda <- lda(species ~ ., data = peng_scaled)

```

```

modelo_lda

```

```

# =====

```

```

# 10. PREDICCIÓN DE NUEVO PINGÜINO

```

```

# =====

```

```

sc <- attr(scale(peng[, vars]), "scaled:center")
ss <- attr(scale(peng[, vars]), "scaled:scale")

```

```

nuevo <- data.frame(
  bill_length_mm = 45,
  bill_depth_mm = 17,
  flipper_length_mm = 210,

```

```

body_mass_g = 4500
)

nuevo_scaled <- as.data.frame((nuevo - sc) / ss)

predict(modelo_lda, newdata = nuevo_scaled)

# =====
# 11. MATRIZ DE CONFUSIÓN Y ERROR
# =====

pred <- predict(modelo_lda)$class

table(Real = peng_scaled$species, Predicho = pred)

error <- mean(pred != peng_scaled$species) * 100
paste("Error total =", round(error, 2), "%")

# ERROR CON VALIDACIÓN CRUZADA
cv_pred <- lda(species ~ ., data = peng_scaled, CV = TRUE)$class
error_cv <- mean(cv_pred != peng_scaled$species) * 100
paste("Error CV =", round(error_cv, 2), "%")

# =====
# 12. FRONTERAS DE CLASIFICACIÓN
# =====

partimat(species ~ ., data = peng_scaled, method = "lda",
  prec = 12,
  image.colors = c("indianred1", "palegreen3", "orchid2"))

```

CÓDIGO DE MANOVA

```
##### MANOVA #####
```

```
# Librerías
```

```
library(palmerpenguins)
```

```
library(biotools)
```

```
library(ggplot2)
```

```
library(ggpubr)
```

```
library(tidyr)
```

```
library(dplyr)
```

```
library(car)
```

```
library(heplots)
```

```
library(corrplot)
```

```
# Variables a usar
```

```
vars <- c("bill_length_mm", "bill_depth_mm", "flipper_length_mm", "body_mass_g")
```

```
# Base
```

```
penguins_clean <- penguins %>%
```

```
  select(all_of(vars), species) %>%
```

```
  na.omit() # eliminamos filas con NA
```

```
penguins_clean$species <- factor(penguins_clean$species)
```

```
# 1. Función Mardia para normalidad multivariada
```

```
mardia_test <- function(data){
```

```
  n <- nrow(data)
```

```
  p <- ncol(data)
```

```
  S <- cov(data)
```

```
  S_inv <- solve(S)
```

```
  Xc <- scale(data, center = TRUE, scale = FALSE)
```

```

# Skewness

b1p <- sum((Xc %*% S_inv %*% t(Xc))^3) / n^2


# Kurtosis

di <- diag(Xc %*% S_inv %*% t(Xc))

b2p <- mean(di^2)


return(list(skewness = b1p, kurtosis = b2p))
}


print("Normalidad multivariada por especie (Mardia):")
for (grupo in levels(penguins_clean$species)) {
  print(paste("Especie:", grupo))
  df_grupo <- penguins_clean[penguins_clean$species == grupo, vars]
  if (nrow(df_grupo) >= 8) {
    res <- mardia_test(df_grupo)
    print(paste("Skewness multivariada:", round(res$skewness, 4)))
    print(paste("Kurtosis multivariada:", round(res$kurtosis, 4)))
  } else {
    print("No se realiza test (n < 8)")
  }
  print(" ")
}


# 2. Homogeneidad de covarianzas

print("BoxM test de homogeneidad de covarianzas:")

biotools::boxM(penguins_clean[, vars], penguins_clean$species)


# 3. Análisis exploratorio: Boxplots

penguins_long <- pivot_longer(penguins_clean, cols = all_of(vars),
                              names_to = "Variable", values_to = "Valor")

```

```
ggplot(penguins_long, aes(x = species, y = Valor, fill = species)) +
  geom_boxplot(alpha = 0.7) +
  facet_wrap(~Variable, scales = "free", ncol = 2) +
  theme_bw() +
  scale_fill_manual(values = c("indianred1", "palegreen3", "orchid2")) +
  theme(legend.position = "none")
```

4. Medias y desviaciones estándar

```
penguins_clean %>%
  group_by(species) %>%
  summarise(
    bill_length_mean = mean(bill_length_mm), bill_length_sd = sd(bill_length_mm),
    bill_depth_mean = mean(bill_depth_mm), bill_depth_sd = sd(bill_depth_mm),
    flipper_length_mean = mean(flipper_length_mm), flipper_length_sd = sd(flipper_length_mm),
    body_mass_mean = mean(body_mass_g), body_mass_sd = sd(body_mass_g)
  )
```

5. Matrices de correlación por grupo

```
dev.new(width=10, height=8) # abrir nueva ventana gráfica
par(mfrow = c(2,2))
for(i in 1:length(levels(penguins_clean$species))) {
  corrplot(cor(penguins_clean[penguins_clean$species == levels(penguins_clean$species)[i], vars]),
    method = "ellipse",
    title = paste("Correlaciones", levels(penguins_clean$species)[i]),
    mar = c(0,0,1,0),
    tl.cex = 0.8)
}
```

6. MANOVA

```
modelo_manova <- manova(cbind(bill_length_mm, bill_depth_mm, flipper_length_mm, body_mass_g) ~ species,
```

```
data = penguins_clean)
print("Resultados MANOVA (Wilks):")
summary(modelo_manova, test = "Wilks")
```

7. ANOVAs individuales por variable

```
print("ANOVAs individuales:")
summary.aov(modelo_manova)
```

8. HE plot multivariado

```
dev.new(width=10, height=8)
heplot(modelo_manova, col = c("indianred1", "palegreen3", "orchid2"))
```